

量子机器学习与人工智能的实现

——基于可计算性与计算复杂性的哲学分析

王凯宁

(山西大学 科学技术哲学研究中心 太原 030006)

摘 要: 量子机器学习是量子计算与机器学习交叉形成的新研究方向,其主要目标是利用量子特性实现对传统机器学习算法的加速。目前已经出现了不少有实际应用价值的量子机器学习算法,这些算法能通过降低计算的复杂性程度,在一些特定领域实现弱人工智能。从可计算性的视角来看,量子机器学习能完成非决定性计算,在理论上可以实现对意识结果的模拟,从而为强人工智能提供支持。

关键词: 量子机器学习; 人工智能; 量子计算; 可计算性; 计算复杂性

中图分类号: N02

文献标识码: A

文章编号: 1674-7062(2019)06-0032-05

量子机器学习 (quantum machine learning, QML) 是量子计算与人工智能研究相交叉形成的一个新领域,其目标主要是设计从数据中学习的量子算法,通过利用量子态的叠加和纠缠等特性,实现对现有机器学习算法的加速。当前,作为实现专用人工智能最核心的技术手段,机器学习已经影响到了科技、社会及人类生活的各个方面。无论是数据挖掘技术还是生物特征识别、自然语言处理还是医疗诊断辅助,乃至自动驾驶技术和智力竞技游戏等等新产品和新技术的开发和进步都与机器学习密切相关。然而,随着各行业信息化程度的提升,技术数据也呈现出急速增长的趋势,这种增长既表现为数据量的指数式扩张,又表现为数据类型、数据结构的爆发式增长。这种增长态势既为机器学习提供了足够的数据支持,又反过来对其处理速度提出了挑战。一些以经典物理学为基础的机器学习算法已经表现出难以及时处理和分析海量数据的问题,由于量子计算在物理原理上就具有“并行 (parallelism)”运算的特性,因此人们期望借助量子计算来改进机器学习算法以解决运算效率问题,量子机器学习正是在

这样的背景下逐渐发展起来的。

一 量子计算与量子机器学习

量子机器学习方法的出现与量子计算理论和技术的发展密不可分。量子计算的思想可以追溯到1980年贝尼奥夫 (P. Benioff) 利用量子力学来描述可逆计算过程的设想^[1],但其概念最早是由费曼 (R. Feynman) 于1982年提出的^[2]。费曼设想了一个利用量子力学的特性 (叠加和纠缠) 完成特定计算任务 (对量子物理系统进行模拟) 的模型,他认为这个模型相比经典计算机有非常巨大的效率优势,后来他将其称为量子力学计算机^[3]。当然,量子计算相对于经典计算的加速性,是在绍尔 (P. Shor) 提出第一个有实际意义的量子算法之后,才受到了大量物理学家和计算机学家的关注。1994年,绍尔设计了一个量子因子分解算法^[4],该算法极大地优化了经典因子分解算法,使解决该问题的时间复杂度实现了指数式降低,即对于原先最好的经典算法而言,需要在数据量的指数倍时间内才能解决的因子分解问题,Shor算法可以在数据的多项式倍时间内

【收稿日期】 2019-03-10

【基金项目】 教育部人文社科研究青年项目“基于量子信息的量子实在论研究”(17YJC720026); 山西省高等学校人文社科重点研究基地项目“信息主义视角下的人工智能哲学研究”(20190101)

【作者简介】 王凯宁(1984-),男,山西沁源人,哲学博士,山西大学科学技术哲学研究中心副教授,研究方向为科学哲学。

完成。并且,由于因子分解问题是经典加密系统 RSA 的理论基础,因此如果该问题能够被高效地解决,就意味着传统数据安全体系的全面崩溃。正是在这种意义下,研究者们对量子计算的加速性产生了极大兴趣,开发了更多量子算法,来解决数据处理时计算效率低下的问题,为后来量子计算与机器学习的结合创造了条件。

作为人工智能研究的重要分支,机器学习主要是利用特定算法从已有数据中进行“学习的”,通过理解先前输入的数据来建立规则,进而对后来的数据进行分析或预测。在 20 世纪末,机器学习逐渐发展到可以完成一些与人类思维密切相关的计算任务,如图像和语音识别、模式识别及策略优化,等等。完成这些任务需要对大量数据进行处理,因此量子计算在数据处理方面的高效性开始受到了研究者的关注。1995 年,卡克(S. Kak)首次将量子计算的思想应用到了传统神经网络中,提出量子神经网络计算的概念^[5]。随后,很多研究者设计了各种不同类型的量子神经网络模型,考察了量子特性对于优化不同结构数据的效率,为人工神经网络的量子化发展奠定了基础。在此基础上,普里布拉姆等人还于 1999 年讨论了利用量子力学来理解人脑信息处理过程的可能性^[6]。当然,量子神经网络的理论研究仅仅是量子机器学习发展的一个方向,传统机器学习中的聚类算法、有监督分类算法、决策树模型等多种算法都已经出现了相应的量子版本。这些算法都属于目前主流的量子机器学习研究,其思路是沿用传统机器学习的整体框架设计,仅在特定的计算阶段调用或设计一些利用量子特性实现加速数据处理的量子算法,来提高传统算法的整体运算效率。

事实上,除了这一类量子机器学习的研究之外,基于经典-量子的划分,我们能够发现,当前量子计算与机器学习的结合还体现在另外两类研究中。第一类研究是利用量子算法的设计思路,在整体上重新设计机器学习算法,从而完成原先难以实现的计算任务。与主流研究相比,这类量子机器学习的优势在于全部的算法步骤均能在某种针对具体任务而特殊设计的专用量子计算机上实现,这就可以回避目前通用量子计算机在物理实现方面存在的困难。但其难度主要体现在算法设计方面,因为这需要对量子系统的动力学特征与传统机器学习过程进行深度比较,以找出其相似性,才能完成算法的重新设计。这类算法的典型代表是量子退火(quantum annealing, QA)算法^[7],其利用量子隧穿效应来寻找

量子势的极小值,从而在寻找全局最优解类的组合优化问题方面表现出相对于传统算法的加速性。该算法目前已被应用于加拿大 D-Wave 公司生产的面向用户的专用量子计算机上,该公司声称其在金融交易轨迹优化、排定航班时刻表、研究蛋白质的最佳折叠方式等具体问题方面都可以有实际应用。第二类研究是利用经典机器学习算法解决量子物理学中遇到的问题。这方面的实际应用主要集中于量子多体物理领域,因为该领域的研究对象是大量微观粒子,物理学家们需要处理的是全部粒子的量子态或者多体量子系统的波函数所对应的信息数据,这种数据的规模会随着多体系统中微观粒子数量的增多而呈指数性扩张,因此机器学习强大的数据处理能力,对于解决量子多体系统中的具体问题而言具有很强的实际价值。目前这类量子机器学习已出现一些代表性的研究,如利于监督学习在凝聚态物理中寻找相变点的位置,利于受限玻尔兹曼机(Restricted Boltzmann Machine)这种生成式随机神经网络来求解量子多体系统的基态,等等。相比主流的量子机器学习而言,这两类研究由于不具有通用性或应用范围仅限于较窄领域(量子物理领域),其研究也相对较少,因此狭义上的量子机器学习指的主要还是利用量子算法对传统机器学习中的部分运算步骤进行加速的那一类。

二 量子机器学习的计算复杂性与弱人工智能的实现

就主流的量子机器学习而言,要实现对现有经典算法中关键过程的加速,一般需要通过三个步骤来完成,分别是:经典数据的量子化转换,运行相应的量子算法,利用量子测量完成计算数据的读取。这三个步骤都会涉及计算复杂性的问题。

正如前文所述,量子计算加速性的根源之一是量子态的叠加性,这对于数据处理而言是非常强大的能力。因为机器学习归根结底是要分析大量的数据,所以第一个步骤,即用量子叠加态来编码经典数据是执行量子算法的前提。“从经典数据到量子数据的转换,需要通过存储器来实现。对于数字型数据,其实对应于一个量子化的数字逻辑电路,或者一个量子子程序,通过执行该子程序将寄存器的状态制备到训练数据对应的状态。”^[8]相比于经典寄存器存储 n 比特的二进制数据需要 2^n 个不同的存储单元,量子寄存器的优势非常明显,它只需 n 个量子位就能达到同样的存储能力。当然,除了节约存储

单元的优势外,量子寄存器在数据寻址方面也必须具有相应的优势。因为与经典算法相同,量子算法在执行“学习”任务的过程时,也需要经常随机抽取或者检索寄存器中的数据,因此这种以量子态为基础的寄存器也应该是可以随机存取的。劳埃德(S. Lloyd)等人于2008年(在理论结构层面)设计了一种能以指数级程度提升内存调用效率的量子随机存取存储器(Quantum Random Access Memory, QRAM)^[9]在数据寻址方面实现了 $O(\log n)$ 级的算法复杂度,为经典数据的量子化表征奠定了基础。

完成量子机器学习的第二步,即量子算法的设计和运行是实现人工智能的核心。通常来说,无论对于经典计算还是量子计算,运行步骤是输入的数据量 N 的多项式函数的算法被认为是有效算法。在计算复杂性视角下,所谓的难问题就是那些找不到多项式时间算法的问题。由于在经典计算机中,很多需要专用人工智能来解决的问题都属于这类难问题,即经典算法在处理数据时所需的运算步骤是数据量 N 的指数级函数,因此量子机器学习的任务就是开发经典算法的量子版本以降低计算复杂性,从而把难问题变成易问题。基本上我们不可能找到一个通用的量子算法,将全部经典计算机的运行过程都直接移植到量子计算机上。事实上,目前已有的量子算法都是针对特定计算任务的,它们大都能实现平方级或指数级的加速效果。例如,一个有代表性的量子算法是由麻省理工学院的劳埃德团队于2009年提出的线性方程组求解算法^[10],对于规模为 $N \times N$ 的矩阵,其运行时间为 $\log N$ 的多项式函数,并且他们基于几条复杂性理论假设证明了:针对该类问题而言,该量子算法相比所有经典算法都能实现指数级加速。更重要的是,现代科技、经济乃至生活中遇到的很多优化问题都能够转化为线性方程组求解问题,因此该量子算法的提出对于诸多领域专用人工智能的实现会起到非常重要的作用。

量子机器学习的第三步是通过量子测量完成计算数据的读取。从哥本哈根解释的视角看——其他量子力学解释对测量有不同理解——测量会使量子叠加态坍塌到一个经典的确定态上。对数据而言,原来以叠加方式存储在 n 个量子寄存器中的 2^n 比特可能数据,就会因测量而转变为1比特确定的数据。但需要注意的是,这种转变不是完全决定论的,要使最后获得的1比特数据是我们期望得到的可用数据,就需要使其在测量时能以更高的概率出现。如果从计算复杂性的视角来看待测量过程的话,我

们就会发现,测量实际上是为量子机器学习的加速性设定了某种限制。假如可以不进行测量,量子计算在理论上能够无限地提升计算效率,只要量子寄存器的数量 n 足够大,那么运算速度提升的效率 $f_c = 2^n$ 可以是无穷大。但是,人作为一种经典世界中的生命形式,是无法认识到以量子叠加态形式存储的数据的,因此,量子测量过程必不可少。正是在这种意义上,研究者们在设计量子算法时既需要考虑如何尽可能高效地利用量子叠加性,以降低运算过程的时间复杂度;还必须考虑如何利用量子纠缠等其他量子特性,使有用数据在测量时能以足够高的概率出现。这两方面设计思想的博弈导致量子机器学习的加速性会存在一个上限,当然这个上限也是因问题而异的。

在讨论了量子机器学习的一般过程之后,让我们来看看人工智能需要面对的计算复杂性问题。笼统地说,人工智能,按照麦卡锡(J. McCarthy)在1956年达特茅斯会议上的设想,就是要让机器的行为同人所表现出的智能行为一样。但是这样的说法过于模糊,因而塞尔(J. Searle)在1980年对强人工智能和弱人工智能进行了区分^[11],强人工智能涉及意识问题,即要使智能机器实现思考和感知等人所具有的认知能力;而弱人工智能则更凸显智能机器的工具属性,即专注于解决特定领域问题的智能研究。由于意识问题的复杂程度远远超出了计算复杂性的范围,因此当前人工智能与计算复杂性研究的交集主要还是落在弱人工智能领域,特别关注的是NP(non-deterministic polynomial,非确定性多项式)类问题。

按照经典计算复杂性理论,NP类问题是指目前还找不到多项式时间算法求解,但能在多项式时间内验证解是否正确的那些问题,前文中提到的大数因子分解问题就是典型的例子。这类问题之所以重要,是因为弱人工智能想要完成的很多具体任务的内核都是此类问题。例如AlphaGo围棋程序需要执行的胜率评估任务就是这样的问题,它需要预测自己和对手未来落子的位置,以评估各自的胜率,向后预测的步数越多,评估就越准确。但计算的复杂程度会随着预测步数的增加而呈指数增长,因而如何将其计算复杂性降低到多项式程度,以便在适当的时间内完成计算任务,是该程序设计的核心要求。

那么,既然以Shor算法为代表的量子算法能有效处理某些特定的NP类问题,那么是否意味着所有NP问题都能找到合适的量子算法以实现有效求

解呢?遗憾的是,目前的理论研究还不能给出一个肯定的回答,Shor 算法等只是一些特例,目前大量 NP 问题的计算复杂性即使在量子计算的语境下也未能被实质性地降低。不过,这并不会阻碍量子算法在弱人工智能领域的应用,因为虽然目前还没有确定性求解 NP 完全(NP-complete)问题的有效算法,但是一些基于量子人工神经网络方案的启发式算法能够做到在有效时间内给出一个相对较好的解。特别是作为量子多体物理和量子信息理论中核心概念的量子纠缠,“可以作为深度学习应用的‘先验知识’:它定量地描述数据集的复杂度,并相应地指导设计人工神经网络的结构”^[12]。在此意义上,量子纠缠可以作为连接真实的微观物理世界与抽象的深度学习理论的桥梁,使得我们可以借助自然量子过程,以高精度近似的方式求解复杂程度相近的函数计算问题,从而推动相应领域弱人工智能的实现。

三 量子机器学习能实现强人工智能吗?

以上我们对量子机器学习问题的讨论,仅局限于计算复杂性方面,并且就弱人工智能的实现而言,由于并不涉及意识问题,因为也不需要计算主义或物理主义的假设。那么,要回答“量子机器学习能否实现强人工智能”这个问题,是否就必须要对意识的本质做出某种本体论承诺呢?事实上,这取决于我们对强人工智能的理解。如果我们认为机器必须表现出人类所特有的感受性方面的特征,强人工智能才算实现的话,那么关于意识的形而上学预设就是不可缺失的;但是,如果我们认为强人工智能的充要条件是:机器所能解决的问题的集合,不小于人类智能可解决的问题的集合,换句话说,无论执行方式是否相同,意识的结果只要能够被机器所模拟,就算实现强人工智能的话,那么我们就不需要考察心灵过程究竟是怎样的,也即不需要关于意识的本体论假设。两种理解相比,显然后者更具建设性,因为在当前针对感受质等问题缺乏实质性科学研究方案的背景下,纠结于意识的本质问题反而会使强人工智能的研究陷入无法开展的悖论:不清楚意识是什么就无法进行计算模拟,反过来不进行计算模拟又无法推进意识研究。因此,接下来我们主要在第二种理解的意义下,从可计算性的视角出发,讨论意识的结果能否被量子机器学习所模拟的问题。

关于可计算的边界问题,哥德尔(K. Gödel)早在 1931 就进行过严格分析,他的第一不完全性定理表明“在任何包含初等数论的形式系统中,都必定

存在一个不可判定命题,即它和它的否定在系统中都不可证。”^[13]该定理讨论的对象是任意一致的形式系统,并无经典与量子之分,这意味着作为形式系统具体实现物的机器必然会遇到不可计算的问题。因此,量子计算机,只是在处理特定计算复杂性问题时效率更高,在不可计算性方面与经典计算机并无差别。那么,根据卢卡斯(J. Lucas)基于不完全性定理而做出的论证——必定存在一个哥德尔语句是一致的形式系统不能证明但人可以看出其是否为真的,机器不能成为心智完整的或适当的模型^[14]——我们似乎应该认为量子机器学习不能实现强人工智能。

然而,针对卢卡斯的论证,计算主义的支持者和反对者们已经进行过多场论战,他们争论的核心问题之一是“心灵是否是一致的形式系统”。其中,费弗曼(S. Feferman)是争论的调和者,他设想了一个“开放模式的公理系统”,认为这是“一种改进的形式系统概念,使得实践的开放性得以允许但同时也受到基础规则的支配,……心灵的数学能力是机械的,因为它完全受到某个开放模式的形式系统的约束”^[15]。虽然费弗曼希望借此弥合对立双方认识上的鸿沟,但他的这种观点实际上更倾向于计算主义,其隐含地说明了心灵可以等价于一台非确定图灵机,即心灵在做出超越一致形式系统的判断时所基于的那种洞察力、想象甚至情感等心理元素,在开放模式的形式系统中也是可以存在的。与这种观点相似的是,马希文曾提出的“非决定性可计算”概念:“所谓一个函数是非决定性可计算的,是指在某种外部信息的协助下可以计算。”^[16]以此为基础,我们认为量子机器学习能够实现强人工智能。

很多反计算主义者将意识不能被机器模拟的原因归结为心灵拥有情感、意愿等非理性因素,却拒绝对这些因素做还原论的考察。但是,如果我们对它们做还原论分析的话,就会发现这些因素可以分为两类:一类可以追溯到外部的非理性源头,如来自于过去并不完善的实践经验;另一类是心灵真正的非理性成分,它们是完全随机的意识过程。第一类成分可被归为外部信息,根据马希文的观点,我们能以非决定性可计算的方式,通过在形式系统中引入一些外部信息,实现对相应心理过程的模拟。第二类成分在理论上不能由经典计算所模拟,因为经典物理学在本质上是决定论的,无法模拟真正的随机过程。然而,作为量子机器学习基础的量子计算,在本质上就是非决定性的,可以产生真正的随机数,因此可以实现对第二类成分的模拟。如果对于意识中这两方面

非理性成分,量子机器学习在原则上都可以模拟的话,那么我们就没理由认为强人工智能无法实现。

最后还应该强调的是,这里讨论的仅是意识的结果能否被量子机器学习所模拟的问题,而不是心灵在本质上是否应该遵循量子力学。不过这种讨论之所以有意义,也需要基于简单性假设,即:意识的特征,只要能被可观察的现象所反映,那么无论其精确本质是什么,或者无论其由什么方式来实现,都应该是等价的。可以看出,这个假设是有较明显的物理主义倾向的,因此,反物理主义者仍然可以就此对强人工智能的可实现性进行反驳。但这种反驳要有说服力,就需要给出两方面的证据:一是证明某些意识过程的确是算法的;二是提出一些非算法的机制,而且这些机制还应该是超越标准量子理论的。这正是量子机器学习为二元论者设置的最大障碍。当然,需要说明的是,量子机器学习目前还仅限于理论和算法方面的研究,随着量子计算机硬件的日趋成熟,它一定会成为推动人工智能发展的重要手段,而且也会成为破解意识之谜的科学基础。

【参 考 文 献】

- [1] BENIOFF P. The computer as a physical system: a microscopic quantum mechanical Hamiltonian model of computers as represented by turing machines[J]. Journal of statistical physics, 1980(5): 563 – 591.
- [2] FEYNMAN R. Simulating physics with computers[J]. International journal of theoretical physics, 1982(6): 467 – 488.
- [3] FEYNMAN R. quantum mechanical computers[J]. Foundations of physics, 1986(6): 507 – 531.
- [4] SHOR P. A logarithms for quantum computation: discrete logarithms and factoring[C]//Proc of the 35th Annual Symposium on the Foundations of Computer Science. New Mexico: IEEE Computer Society Press, 1994: 124 – 134.
- [5] KAK S. On quantum neural computing[J]. Information sciences, 1995(3 – 4): 143 – 160.
- [6] PRIBRAM K. Quantum holography: is it relevant to brain function? [J]. Information science, 1999(1 – 4): 97 – 102.
- [7] KADOWAKI T, HIDETOSHI N. Quantum annealing in the transverse Ising model [J]. Physics review E, 1998(5): 5355 – 5364.
- [8] 陆思聪, 郑昱, 王晓霆, 等. 量子机器学习[J]. 控制理论与应用, 2017(11): 1431.
- [9] GIOVANNETTI V, LLOYD S, MACCONE L. Quantum random access memory [J]. Physical review letters, 2008(16): 160501.
- [10] HARROW A, HASSIDIM A, LLOYD S. Quantum algorithm for linear systems of equations [J]. Physical review letters, 2009(15): 150502.
- [11] SEARLE J. Minds, brains, and programs [J]. Behavioral and brain sciences, 1980(3): 417 – 457.
- [12] 程嵩, 陈靖, 王磊. 量子纠缠: 从量子物质态到深度学习[J]. 物理, 2017(7): 421.
- [13] 刘晓力. 哥德尔对心—脑—计算机问题的解[J]. 自然辩证法研究, 1999(11): 30.
- [14] LUCAS J. Minds, machines and Gödel [J]. Philosophy, 1961(137): 112 – 127.
- [15] 刘大为. 哥德尔定理: 对卢卡斯 – 彭罗斯论证的新辨析[J]. 科学技术哲学研究, 2017(4): 28.
- [16] 马希文. 什么是可计算性 [J]. 计算机研究与发展, 1988(11): 15.

Quantum Machine Learning and the Realization of Artificial Intelligence:

Philosophical Analysis Based on Computability and Computational Complexity

WANG Kai – ning

(Research Center for Philosophy of Science and Technology, Shanxi University, Taiyuan 030006, China)

Abstract: Quantum machine learning is a new interdisciplinary direction of quantum computing and machine learning. Its main goal is to speed up the traditional machine learning algorithm by quantum properties. At present, there have been some practical quantum machine learning algorithms which are of practical application value and can realize weak artificial intelligence in some specific fields, by reducing the computational complexity. From the view of computability, quantum machine learning can perform non – deterministic computation and simulate the results of consciousness theoretically, thus it can support the view that strong artificial intelligence is achievable.

Key words: quantum machine learning; artificial intelligence; quantum computing; computability; computational complexity

(责任编辑 殷杰)